

大數據資料處理

就大數據分析而言可以將資料分成2類,

1. 數字型態: 一般而言, 作完資料標準化, 就可以作為模型的輸入

2. 如果是類別型資料 (Categorical Data) eg. [紅, 藍, 綠]

就必須作

a. Label Encoding (標籤編碼) eg. [0, 1, 2]

或是

b. One-Hot Encoding (獨熱編碼) eg. [100, 010, 001]

-

Q1: 以下敘述正確嗎? 有需要修正/微調嗎?

Q2: 請就以上再補充說明

你的整體概念是**正確**的方向, 但如果用在教學或正式說明, 建議做一些「精確化與補強」, 會更完整 🍌

✓ Q1：是否正確？需要修正嗎？

✓ 修正後較精準版本（建議這樣寫）

就大數據分析或機器學習而言，資料可大致分為：

1 數值型資料 (Numerical Data)

- 例如：年齡、收入、溫度
- 通常需要進行標準化 (Standardization) 或正規化 (Normalization)
- 才適合輸入模型（特別是距離型或梯度型模型）

👉 修正重點：

- ❌ 「一定要標準化」→ 太絕對
- ✅ 「通常需要」→ 比較正確（如決策樹不一定需要）

2 類別型資料 (Categorical Data)

例如：[紅, 藍, 綠]

需轉換為數值，常見方法：

a. Label Encoding (標籤編碼)

→ [紅, 藍, 綠] → [0, 1, 2]

b. One-Hot Encoding (獨熱編碼)

→

紅 → [1,0,0]

藍 → [0,1,0]

綠 → [0,0,1]

👉 修正重點：

- One-Hot 建議寫成 [1,0,0] (比 100 清楚)
- 強調「模型不能直接吃文字」→ 才是本質原因

✅ Q2：補充說明（這部分很重要🔥）

這裡是你原本內容最值得加強的地方👉

◆ 1 類別型資料其實還可以再細分

(1) Nominal（無順序）

例如：

- 顏色：[紅, 藍, 綠]

👉 只能用 One-Hot Encoding

❌ Label Encoding 會產生「假順序」

(2) Ordinal（有順序）

例如：

- 等級：[低, 中, 高]

👉 可以用 Label Encoding：

- 低=0, 中=1, 高=2 ✅ (合理)

◆ 2 Label Encoding 的陷阱（很常考！）

如果你寫：

紅=0, 藍=1, 綠=2

模型可能會「誤以為」：

👉 綠 > 藍 > 紅 (有大小關係)

⚠️ 對以下模型會有問題：

- 線性回歸

- KNN
- SVM
- 神經網路

◆ 3 One-Hot Encoding 的優缺點

✓ 優點

- 不會引入大小關係（最安全）
- 適用大多數模型

✗ 缺點

- 維度爆炸（High Dimensionality）
 - 類別很多 → 欄位很多

◆ 4 什麼時候不用 One-Hot ？

例如：

👉 類別很多（上千種）

- 商品ID
- 使用者ID

這時候會用：

- Target Encoding
- Embedding（深度學習）

◆ 5 不同模型的需求（很加分🔥）

模型類型	是否需要標準化	類別編碼
線性模型	需要	One-Hot
KNN / SVM	需要	One-Hot
神經網路	需要	One-Hot / Embedding
決策樹	✗不需要	Label / One-Hot 都可
Random Forest	✗不需要	Label / One-Hot 都可

✅ 總結（幫你整理成一句話）

👉 你的原始說法是「方向正確，但略為簡化」

最佳版本一句話：

數值資料通常需標準化後輸入模型；類別資料需轉換為數值（如 Label Encoding 或 One-Hot Encoding），且需依資料是否具有順序性與模型特性選擇合適方法。

如果你要，我可以幫你把這段整理成「考試答案版本（精簡版）」或「投影片版本」🔥