

Label vs One-Hot Encoding

Label Encoding 與 One-Hot Encoding 的差別
請舉例說明清楚

在機器學習中，**類別資料 (categorical data)** 不能直接餵給模型，因此需要轉換成數值。最常見的兩種方法就是：

◆ 1. Label Encoding (標籤編碼)

👉 概念：

把每個類別「直接編號」成一個整數

🔗 範例

假設有一個欄位：

顏色
紅
藍
綠

使用 Label Encoding：

顏色	編碼
紅	0
藍	1
綠	2

👉 Python 範例：

Python

```
from sklearn.preprocessing import LabelEncoder
```

```
data = ['紅', '藍', '綠']
le = LabelEncoder()
encoded = le.fit_transform(data)

print(encoded)
```

👉 輸出：

```
[0 1 2]
```

⚠ 問題 (很重要)

模型會「誤以為有大小關係」：

👉 例如：

紅(0) < 藍(1) < 綠(2)

但實際上顏色是沒有大小順序的！

◆ 2. One-Hot Encoding (獨熱編碼)

👉 概念：

每個類別變成一個欄位，用 0/1 表示是否屬於該類別

📌 範例

原始資料：

顏色
紅
藍
綠

One-Hot Encoding：

紅	藍	綠
1	0	0
0	1	0
0	0	1

👉 Python 範例：

Python

```
import pandas as pd
```

```
df = pd.DataFrame({'顏色': ['紅', '藍', '綠']})
```

```
one_hot = pd.get_dummies(df['顏色'])
```

```
print(one_hot)
```

✅ 優點

- 不會產生大小關係（非常重要）
- 適合大多數模型（特別是線性模型）

⚠️ 缺點

- 類別多 → 欄位爆炸（維度變高）

🔥 重點比較（超重要）

比較項目	Label Encoding	One-Hot Encoding
表示方式	一個數字	多個欄位（0/1）
是否有順序	❗ 有（可能誤導）	✅ 沒有
記憶體	省	比較大
適合模型	樹模型（Random Forest, XGBoost）	線性模型、NN

🎯 什麼時候用哪個？

✅ 用 Label Encoding：

- 類別本身「有順序」
 - 例：小 / 中 / 大
- 或使用：
 - Decision Tree
 - Random Forest
 - XGBoost

✅ 用 One-Hot Encoding：

- 類別「沒有順序」（大多數情況）
 - 例：顏色、城市、性別
- 用於：
 - Logistic Regression
 - Linear Regression
 - Neural Network

💡 一句話總結

👉 Label Encoding = 給編號（可能有順序問題）

👉 One-Hot Encoding = 展開成多欄（最安全）

如果你要做的是「詐欺偵測（fraud_reported）」這種分類問題，我可以幫你判斷每個欄位該用哪種 encoding（很實用）。

```
import pandas as pd

df = pd.DataFrame({'顏色': ['紅', '藍', '綠']})
one_hot = pd.get_dummies(df['顏色'])

print(one_hot)
-
```

output是

```
import pandas as pd
      紅    綠    藍
0  True False False
1  False False  True
2  False  True False
```

非我們所希望的, 應為數字 0/1, 請 給新的程式

你觀察得很好 🍌

`pd.get_dummies()` 出現 **True / False**, 通常是因為目前 pandas 版本預設回傳 **布林值 (bool)**。

✅ 解法 1 (最簡單, 推薦)

👉 指定 `dtype=int`

Python

```
import pandas as pd

df = pd.DataFrame({'顏色': ['紅', '藍', '綠']})

one_hot = pd.get_dummies(df['顏色'], dtype=int)

print(one_hot)
```

✅ 輸出結果 (你想要的)

```
      紅    綠    藍
0     1     0     0
1     0     0     1
2     0     1     0
```

✅ 解法 2 (已產生後再轉型)

如果你已經有 True/False :

Python

```
one_hot = pd.get_dummies(df['顏色']).astype(int)
```

🔍 為什麼會這樣？

在新版 **pandas** 中：

- 預設 `dtype` 可能是 **bool**

- 因為 True/False 更省記憶體
- 但在機器學習中通常會轉成 0/1

小補充（實務很重要）

如果你是要丟進模型（例如 sklearn）：

- 👉 True/False 通常也可以用（會自動轉 1/0）
- 👉 但建議統一用 `int`，避免混亂

一句話結論

- 👉 想要 0/1：
加 `dtype=int` 就對了

如果你接下來要做的是 `fraud_reported` 的特徵工程，我可以幫你整個欄位一次轉好（哪些用 One-Hot、哪些用 Label Encoding）。