

刪除欄位原因解析

From the above plot, we can see that there is high correlation between age and months_as_customer. We will drop the "Age" column. Also there is high correlation between total_claim_amount, injury_claim, property_claim, vehicle_claim as total claim is the sum of all others. So we will drop the total claim column.

```
df.drop(columns = ['age', 'total_claim_amount'], inplace = True, axis = 1)
```

為何要刪此2個欄位呢？

這段話其實在做一件很重要的事：**降低特徵之間的高度相關性（multicollinearity，多重共線性）**，讓模型更穩定、效果更好。

我們拆成兩個部分說明👉

一、為什麼刪掉 age？

👉 原因：和 months_as_customer 高度相關

- age（年齡）
- months_as_customer（成為客戶的月數）

這兩個變數本質上是「高度重疊的資訊」：

- 👉 客戶越老 → 通常加入時間越長
- 👉 客戶越年輕 → 通常加入時間越短

所以模型其實在「重複看同一件事」

！問題在哪？

如果不刪，會出現：

- 模型「混亂」：不知道該相信哪一個變數
- 係數不穩定（尤其是線性模型）
- 解釋性變差（feature importance 失真）

✓ 解法

👉 保留一個就好（通常選資訊較直接或業務上較有意義的）

這裡選：

- 留 months_as_customer
- 刪 age

二、為什麼刪掉 total_claim_amount ?

👉 原因：它是其他欄位的加總

```
total_claim_amount
= injury_claim
+ property_claim
+ vehicle_claim
```

! 問題在哪？

這叫做：

👉 完全線性相關 (perfect multicollinearity)

會造成：

- 模型可以「作弊」直接用總和推回細項
- 特徵變得冗餘 (redundant)
- 有些模型 (如線性回歸) 甚至會出錯 (矩陣不可逆)

✓ 解法

👉 二選一策略：

保留	刪除
各細項 (injury / property / vehicle)	total_claim_amount

或

保留	刪除
total_claim_amount	各細項

🔪 為什麼這裡選刪 total ?

因為：

👉 細項資訊比較細緻 (更有解釋力)

例如：

- 哪一種理賠對 fraud 影響最大？
- 車損 vs 人傷 哪個比較關鍵？

三、總結一句話

這兩個刪除動作的核心原則是：

四、你可以記這個面試/考試重點

👉 常見刪除特徵原因：

1. 高相關 (correlation 高)
 2. 完全線性關係 (加總、比例)
 3. 重複資訊 (redundant features)
-

如果你要，我可以幫你補一個：

👉 「什麼時候『不應該』刪？」（很多人這裡會踩雷，考試很常出）