

大數據前處理與範例

Q1: 大數據分析的資料前處理 (Preprocessing)
包含那些工作? 請列出說明, 最好有 python 的簡單範例.

大數據分析中的**資料前處理 (Preprocessing)**，就是把「原始資料 → 可用於分析/建模的資料」的過程。這一步非常關鍵，常常佔整個專案 60~80% 的時間。

下面幫你整理「常見工作項目 + 說明 + Python 範例」👉

◆ 1. 資料清理 (Data Cleaning)

👉 解決資料錯誤、不完整、不一致問題

常見工作：

- 處理缺失值 (Missing Value)
- 移除重複資料 (Duplicate)
- 修正錯誤資料 (如負年齡)
- 統一格式 (日期、字串)

Python 範例

```
import pandas as pd

df = pd.DataFrame({
    'name': ['A', 'B', 'B', None],
    'age': [20, None, None, 25]
})

# 移除重複
df = df.drop_duplicates()

# 補缺失值
df['age'] = df['age'].fillna(df['age'].mean())

# 刪除缺失資料
df = df.dropna(subset=['name'])

print(df)
```

◆ 2. 資料轉換 (Data Transformation)

👉 把資料轉成模型容易理解的形式

常見工作：

- 類別 → 數值 (Encoding)
- 標準化 / 正規化 (Scaling)

- 型別轉換 (Type Casting)

Python 範例

```
from sklearn.preprocessing import LabelEncoder, StandardScaler

# 類別轉數值
df['gender'] = ['M', 'F', 'M']
le = LabelEncoder()
df['gender'] = le.fit_transform(df['gender'])

# 標準化
scaler = StandardScaler()
df[['age']] = scaler.fit_transform(df[['age']])
```

◆ 3. 資料整合 (Data Integration)

👉 多來源資料合併

常見工作：

- Join / Merge
- 欄位對齊
- 去除重複來源

Python 範例

```
df1 = pd.DataFrame({'id': [1,2], 'name': ['A','B']})
df2 = pd.DataFrame({'id': [1,2], 'score': [90,80]})

df = pd.merge(df1, df2, on='id')
print(df)
```

◆ 4. 資料縮減 (Data Reduction)

👉 減少資料量但保留重要資訊

常見工作：

- 特徵選擇 (Feature Selection)
- 降維 (PCA)
- 抽樣 (Sampling)

Python 範例 (簡單抽樣)

```
# 隨機抽取 50% 資料
df_sample = df.sample(frac=0.5)
```

◆ 5. 資料離散化 (Discretization)

👉 把連續資料轉成區間（分箱）

Python 範例

```
df['age_group'] = pd.cut(df['age'],
                        bins=[0,18,30,50],
                        labels=['child','young','adult'])
```

◆ 6. 資料重塑（Reshape）

👉 改變資料結構（你之前問過的 Pivot / Unpivot）

Python 範例

```
# Pivot
df_pivot = df.pivot(index='id', columns='subject', values='score')

# Unpivot
df_melt = pd.melt(df, id_vars=['id'])
```

◆ 7. 特徵工程（Feature Engineering）

👉 創造新欄位讓模型更好學習

常見：

- 日期拆解（年/月/日）
- 組合欄位
- 計算比例

Python 範例

```
df['date'] = pd.to_datetime('2025-03-01')

df['year'] = df['date'].dt.year
df['month'] = df['date'].dt.month
```

◆ 8. 異常值處理（Outlier Handling）

👉 找出不合理數據（例如：薪水 1 億）

Python 範例

```
# 移除極端值
df = df[df['age'] < 100]
```

◆ 9. 資料標記（Labeling / Annotation）

👉 👉 這個就是你問的「人工標記」

- ✓ 屬於前處理的一部分
- ✓ 尤其在 AI / 深度學習（如影像、NLP）很重要

例如：

- 圖片標註（貓 / 狗）
- X光標記蛀牙（你現在做的！）

◆ 總整理（考試/報告版）

資料前處理通常包含：

1. 資料清理（Cleaning）
2. 資料轉換（Transformation）
3. 資料整合（Integration）
4. 資料縮減（Reduction）
5. 資料離散化（Discretization）
6. 資料重塑（Reshape）
7. 特徵工程（Feature Engineering）
8. 異常值處理（Outlier）
9. 資料標記（Labeling）

🔥 重點一句話

👉 **Preprocessing = 把「髒資料 → 可訓練資料」的全部過程**

如果你要，我可以幫你再補一版：

- ✓ 「ETL vs Preprocessing 的關係」
- ✓ 或「專門針對影像（你牙齒X光）的前處理流程」

請完備以下4及5, python 的程式, 先產生Data, 再下指令, 使之單一區塊, 都是可以執行的

4. 資料縮減（Data Reduction）

Python 範例（簡單抽樣）

隨機抽取 50% 資料

```
df_sample = df.sample(frac=0.5)
```

-

5. 資料離散化（Discretization）

```
df['age_group'] = pd.cut(df['age'],
                        bins=[0,18,30,50],
                        labels=['child','young','adult'])
```

很好，這題我幫你整理成「可以直接執行的一整段程式」，包含：

- 先建立 DataFrame
- 再做「資料縮減」與「資料離散化」

✓ 4 + 5 完整 Python 範例（可直接執行）

```
import pandas as pd
import numpy as np

# =====
# 1 產生模擬資料
# =====
np.random.seed(0) # 讓結果可重現

df = pd.DataFrame({
    'id': range(1, 21),
    'age': np.random.randint(10, 60, 20),
    'income': np.random.randint(20000, 80000, 20)
})

print("=== 原始資料 ===")
print(df)

# =====
# 2 資料縮減 (Data Reduction)
# =====
# 隨機抽取 50% 資料
df_sample = df.sample(frac=0.5, random_state=1)

print("\n=== 抽樣後資料 (50%) ===")
print(df_sample)

# =====
# 3 資料離散化 (Discretization)
# =====
df['age_group'] = pd.cut(
    df['age'],
    bins=[0, 18, 30, 50, 100],
    labels=['child', 'young', 'adult', 'middle_age']
)

print("\n=== 加入年齡分群後 ===")
print(df)
```

補充說明（幫你上課用）

Data Reduction（資料縮減）

```
df.sample(frac=0.5)
```

👉 意思是：

- `frac=0.5` → 抽 50% 資料
- 常用於：
 - 大數據太大 → 降低運算量

- 建立測試資料

Discretization (資料離散化)

`pd.cut(...)`

👉 把「連續數值 → 類別區間」

例如：

- 25歲 → young
- 45歲 → adult

👉 常用於：

- 分群分析
- 決策樹模型
- 報表呈現 (更直覺)

小提醒 (很重要)

你原本的 bins：

```
bins=[0,18,30,50]
```

👉 會漏掉 >50 的資料

所以我幫你補成：

```
bins=[0,18,30,50,100]
```

如果你要更進階一點，我可以幫你補 👉

- ✓ 等頻分箱 (qcut)
- ✓ 自動最佳分箱 (機器學習用)
- ✓ 或「資料縮減 + PCA 降維」完整版

同理

請完備以下6.資料重塑及8.異常值處理, python 的程式, 先產生Data, 再下指令, 使之單一區塊, 都是可以執行的

很好，這題我一樣幫你整理成「一整段可直接執行的 Python 程式」，包含：

- 先產生資料
- 再做  資料重塑 (Pivot / Unpivot)
- 再做  異常值處理 (Outlier Handling)

✓ 6 + 8 完整 Python 範例（可直接執行）

```
import pandas as pd
import numpy as np

# =====
# 1 產生模擬資料
# =====
np.random.seed(0)

df = pd.DataFrame({
    'id': np.repeat(range(1, 6), 3), # 5個人, 每人3科
    'subject': ['Math', 'English', 'Science'] * 5,
    'score': np.random.randint(50, 100, 15)
})

# 人為加入異常值
df.loc[2, 'score'] = 999 # 極端高分
df.loc[7, 'score'] = -50 # 不合理低分

print("=== 原始資料 (含異常值) ===")
print(df)

# =====
# 2 資料重塑 (Reshape)
# =====

# Pivot (長表 → 寬表)
df_pivot = df.pivot(index='id', columns='subject', values='score')

print("\n=== Pivot (寬表) ===")
print(df_pivot)

# Unpivot (寬表 → 長表)
df_melt = pd.melt(df_pivot.reset_index(), id_vars=['id'],
                  var_name='subject', value_name='score')

print("\n=== Unpivot (轉回長表) ===")
print(df_melt)

# =====
# 3 異常值處理 (Outlier Handling)
# =====

# 方法1: 設定合理範圍 (例如 0~100 分)
df_clean = df[(df['score'] >= 0) & (df['score'] <= 100)]

print("\n=== 移除異常值 (0~100) ===")
print(df_clean)

# 方法2: 使用 IQR (四分位距) 偵測異常值
Q1 = df['score'].quantile(0.25)
Q3 = df['score'].quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

df_iqr = df[(df['score'] >= lower_bound) & (df['score'] <= upper_bound)]

print("\n=== IQR方法移除異常值 ===")
print(df_iqr)
```

補充說明（上課重點版）

6 資料重塑（Reshape）

✓ Pivot（長 → 寬）

```
df.pivot(index='id', columns='subject', values='score')
```

👉 結果：

id	Math	English	Science
1	88	92	85

✓ Unpivot（寬 → 長）

```
pd.melt(...)
```

👉 把欄位轉回列（很常用在資料整理）

8 異常值處理（Outlier）

✓ 方法1：規則法（簡單）

```
df[(df['score'] >= 0) & (df['score'] <= 100)]
```

👉 適合：

- 成績
- 年齡
- 金額（有明確範圍）

✓ 方法2：IQR（統計法）

```
Q1 = df['score'].quantile(0.25)  
Q3 = df['score'].quantile(0.75)
```

👉 判斷範圍：

```
[Q1 - 1.5*IQR , Q3 + 1.5*IQR]
```

👉 優點：

- 不需要先知道合理範圍
- 常用於資料分析 / ML 前處理

一句話重點

👉 Reshape = 改資料結構（長↔寬）

👉 Outlier = 找出不合理數據並處理

如果你要，我可以再幫你整理一份👉

- ✅ 「前處理完整流程（考試一頁筆記版）」
- ✅ 或「老師最愛考的 10 個 preprocessing 題型」