

大數據資料擷取整理

研一的大數據分析課程, 關於:擷取/收集所需資料
請整理課程內容

以下是一個 研究所一年級「大數據分析 (Big Data Analytics)」課程中「資料擷取 / 資料收集 (Data Acquisition)」單元的完整整理, 適合 約 2-3 小時課程使用, 也可作為教學投影片或講義架構。

研究所課程：Big Data Analytics

單元：資料擷取與資料收集 (Data Acquisition)

一、為什麼資料擷取很重要

在大數據分析流程中, 資料擷取是 **第一個關鍵步驟**。

典型的大數據分析流程：

1. Problem Definition
2. **Data Acquisition (資料收集)**
3. Data Cleaning
4. Data Preprocessing
5. Data Analysis / Machine Learning
6. Model Evaluation
7. Deployment / Visualization

若資料品質不佳, 即使使用再好的 AI / ML 模型, 結果也會不準確。

常見說法：

Garbage In, Garbage Out (GIGO)

二、資料來源 (Data Sources)

大數據資料通常來自多種來源, 可分為以下幾類：

1. 結構化資料 (Structured Data)

通常來自資料庫。

例如：

- 醫院 HIS 系統

- 銀行交易資料
- ERP 系統
- CRM 系統

常見格式：

- SQL Database
- CSV
- Excel

範例：

Patient_ID	Age	Gender	Diagnosis
1001	45	M	Diabetes
1002	60	F	Hypertension

2. 半結構化資料 (Semi-structured Data)

資料具有一定結構，但不是固定表格。

常見格式：

- JSON
- XML
- Log files

例如：

```
{
  "patient_id": 1001,
  "age": 45,
  "diagnosis": "diabetes"
}
```

常見來源：

- Web API
- IoT devices
- 系統 log

3. 非結構化資料 (Unstructured Data)

沒有固定結構。

例如：

- 文字 (Text)

- 影像 (Image)
- 語音 (Audio)
- 影片 (Video)

應用例子：

醫療影像：

- X-ray
- CT
- MRI

社群資料：

- Twitter
- Facebook
- YouTube

三、資料取得方式 (Data Collection Methods)

1. 資料庫擷取 (Database Extraction)

從資料庫系統取得資料。

常用技術：

- SQL Query
- ETL (Extract, Transform, Load)

範例：

```
SELECT patient_id, age, diagnosis
FROM patients
WHERE diagnosis = 'diabetes'
```

常用資料庫：

- MySQL
- PostgreSQL
- MongoDB
- MS SQL Server

2. Web Scraping (網頁資料擷取)

從網站抓取資料。

常用工具：

Python :

- BeautifulSoup
- Scrapy
- Selenium

範例流程：

Website → HTML → Parser → Dataset

簡單 Python 範例：

```
import requests
from bs4 import BeautifulSoup

url = "https://example.com"
response = requests.get(url)

soup = BeautifulSoup(response.text, "html.parser")

title = soup.title.text
print(title)
```

3. API 取得資料 (Application Programming Interface)

許多平台提供 API 讓研究者取得資料。

例如：

- Twitter API
- Google Maps API
- OpenWeather API

範例：

```
import requests

url = "https://api.openweathermap.org/data"
response = requests.get(url)

data = response.json()
```

優點：

- 結構清楚
- 合法
- 自動化

4. 公開資料集 (Open Datasets)

研究最常使用。

常見來源：

1. Kaggle

資料科學競賽平台。

包含：

- 醫療資料
 - 金融資料
 - 影像資料
 - NLP資料
-

2. UCI Machine Learning Repository

著名學術資料庫。

例如：

- Iris dataset
 - Heart disease dataset
 - Breast cancer dataset
-

3. 政府開放資料

例如：

台灣：

- 政府資料開放平台
 - 健保資料庫
-

5. IoT Sensors（感測器資料）

智慧城市、智慧醫療常見。

例如：

- 心跳監測
- 空氣品質
- 溫度
- GPS

資料特性：

- 即時資料（Streaming data）
 - 高頻率
-

四、大數據的資料特性（5V）

大數據通常具有以下特性：

特性	說明
Volume	資料量巨大
Velocity	資料產生速度快
Variety	資料類型多樣
Veracity	資料真實性
Value	資料價值

例子：

醫療影像 AI：

- Volume：數萬張 X-ray
- Variety：影像 + 文字報告
- Velocity：醫院每天新增資料

五、資料擷取流程（Data Acquisition Pipeline）

典型流程：

```

Data Sources
  ↓
Data Extraction
  ↓
Data Storage
  ↓
Data Cleaning
  ↓
Data Analysis

```

常見架構：

```

Web / Sensors / Database
  ↓
ETL Pipeline
  ↓
Data Warehouse
  ↓
Machine Learning

```

六、資料品質問題（Data Quality Issues）

資料收集時常見問題：

1 Missing Data

缺失資料

例如：

Age	Gender	Income
35	M	NULL

2 Duplicate Data

重複資料

3 Noisy Data

資料錯誤

例如：

年齡 = 500

4 Inconsistent Data

例如：

Male
M
male

七、資料倫理與隱私（Data Ethics）

資料收集必須注意：

1 隱私保護

例如：

醫療資料必須 **去識別化（De-identification）**

2 法規

常見法規：

- GDPR（歐盟）
 - HIPAA（美國醫療）
 - 個資法（台灣）
-

3 IRB（人體研究倫理）

醫療研究通常需：

Institutional Review Board

八、案例（Example）

醫療 AI：蛀牙影像分析

資料來源：

1. 醫院 PACS 系統
2. Dental X-ray
3. 醫師標註

資料流程：

```

X-ray Images
↓
Annotation
↓
Dataset
↓
Deep Learning
  
```

九、課堂實作建議

可以讓學生做簡單練習：

練習1

下載 Kaggle dataset：

例如：

[Heart Disease Dataset](#)

任務：

- 查看資料
 - 了解欄位
 - 找 missing data
-

練習2

簡單 Web Scraping

抓取：

- 天氣資料
 - 股票資料
-

十、課程總結

資料擷取是大數據分析的 **第一個重要步驟**。

資料來源包含：

- Database
- Web
- API
- Sensors
- Open datasets

資料品質直接影響：

- AI模型
- 預測準確度
- 分析結果

如果需要，我可以再幫您整理 下一個單元（研究所課程很重要）：

- 1 Data Understanding（資料理解）
- 2 Data Cleaning（資料清理）
- 3 Data Preprocessing（資料前處理）

我也可以幫您做成 3小時研究所課程的 PPT 架構（約 35 張投影片），會非常適合教學使用。

就以上內容, 請再說明

1. 典型的大數據分析流程中的 7.Deployment / Visualization 的Deployment意思
2. 請說明ETL (Extract, Transform, Load) 中的Load意思

以下是對兩個概念的進一步說明，適合在 研究所「大數據分析」課程中補充解釋。

1 Deployment / Visualization 中的 Deployment 是什麼意思

在 大數據分析或機器學習流程中，Deployment 指的是：

將已訓練完成的模型或分析系統，正式應用到真實環境中使用。

也就是說，模型不再只是研究或實驗，而是 真正開始提供預測或決策支援。

大數據 / AI 流程回顧

典型流程：

1. Problem Definition
2. Data Acquisition
3. Data Cleaning

4. Data Preprocessing
5. Model Training
6. Model Evaluation
7. **Deployment / Visualization**

Deployment 的概念

Deployment = 模型上線 (Model in Production)

也就是：

```
研究模型
↓
測試模型
↓
正式系統使用
```

Deployment 的常見形式

1. Web API 服務

將模型變成 API。

例如：

```
Input: X-ray image
↓
AI model
↓
Output: caries probability
```

使用方式：

```
POST /predict
```

輸入影像 → 回傳預測結果

2. 系統整合

將 AI 模型整合到現有系統，例如：

- 醫院 HIS 系統
- PACS 影像系統
- 電商推薦系統
- 金融風控系統

例子：

牙科 AI 系統

Dental X-ray
↓
AI segmentation
↓
標示蛀牙區域
↓
醫師診斷輔助

3. 批次預測 (Batch Prediction)

每天或每週自動預測。

例如：

每天晚上
新資料 → AI模型 → 預測結果

例子：

- 信用卡詐騙偵測
- 銷售預測

4. 即時預測 (Real-time Prediction)

資料進來就立即預測。

例如：

使用者點擊 → AI推薦系統 → 推薦商品

常見應用：

- Netflix 推薦
- Amazon 推薦
- Google 搜尋排序

Deployment 的重要性

很多 AI 專案 最大的問題不是模型，而是部署。

常見問題：

- 模型無法整合到系統
- 預測速度太慢
- 模型無法更新

因此出現一個新領域：

MLOps (Machine Learning Operations)

負責：

- 模型部署

- 模型監控
- 模型更新

2 ETL 中的 Load 是什麼意思

ETL 是資料工程中非常重要的概念：

ETL = Extract → Transform → Load

意思是：

資料擷取 → 資料轉換 → 資料載入

1. Extract（擷取）

從資料來源取得資料。

來源例如：

- Database
- Web
- API
- CSV
- Log

例子：

SQL Database
↓
SELECT * FROM patients

2. Transform（轉換）

將資料轉換成可分析格式。

常見工作：

- 清理資料
- 去除錯誤
- 標準化格式
- 資料整合

例如：

原始資料：

Gender
Male

Gender
M
male

轉換後：

Gender
M

3. Load（載入）

Load 的意思是：

將整理好的資料存入目標系統（Target System）

通常會存入：

1 Data Warehouse（資料倉儲）

例如：

- Snowflake
- Redshift
- BigQuery

2 Database

例如：

- MySQL
- PostgreSQL
- MS SQL

3 Data Lake

例如：

- Hadoop
- Amazon S3

ETL 的完整流程

資料來源
(Database / API / Web)

↓
Extract
擷取資料

↓
Transform
清理 + 整理

↓
Load
存入 Data Warehouse

醫療資料 ETL 例子

假設做醫療 AI：

醫院 HIS
PACS 影像系統
Excel 報表

ETL：

Extract
↓
抓取病患資料

Transform
↓
去除錯誤
標準化格式

Load
↓
存入研究資料庫

最後形成：

AI Training Dataset

簡單記憶方式（課堂可以教學生）

ETL 就是：

Extract = 拿資料
Transform = 整理資料
Load = 存資料

如果您是 **研究所大數據課程**，其實下一個很重要的觀念是：

ELT（現代大數據常用）

Extract → Load → Transform

這是 **Big Data / Cloud Data Engineering** 新架構。

如果需要，我可以再幫您整理：

ETL vs ELT（研究所課程非常常考的一題）。

好, 請整理一下: ETL vs ELT

以下是 研究所「大數據分析 / Data Engineering」課程中常講的概念：ETL vs ELT 的整理版本，適合用於 教學講義或投影片。

ETL vs ELT

在資料工程（Data Engineering）與大數據系統中，資料整合流程常見兩種模式：

- ETL (Extract – Transform – Load)
- ELT (Extract – Load – Transform)

兩者的差別主要在於 資料轉換（Transform）發生的時間與位置。

一、ETL（Extract – Transform – Load）

ETL流程

```

Data Source
  ↓
Extract
  ↓
Transform
  ↓
Load
  ↓
Data Warehouse
  
```

ETL步驟說明

1 Extract（資料擷取）

從資料來源取得資料：

- Database
- API
- CSV
- Excel
- Log file

例如：

```
SELECT * FROM patients
```

2 Transform (資料轉換)

在載入資料庫之前先進行資料處理：

常見操作：

- Data Cleaning
- 資料格式轉換
- 缺失值處理
- 去除重複資料
- 資料整合

例如：

Gender
Male
male
M

轉換為：

Gender
M

3 Load (資料載入)

將整理好的資料存入目標系統：

例如：

- Data Warehouse
- SQL Database
- Analytics Database

ETL特點

特徵：

- 先整理資料
- 再存入資料庫

優點：

- 資料品質較高

- 資料庫負擔較小


缺點：

- 前處理時間較長
- 不適合超大資料

二、ELT (Extract – Load – Transform)

隨著 **Cloud Computing** 與 **Big Data** 技術發展，ELT 逐漸成為主流。

ELT 流程



ELT 步驟說明

1 Extract

從資料來源擷取資料。


來源：

- IoT
- Web
- Database
- Logs
- Social media

2 Load

直接將 **原始資料 (Raw Data)** 載入系統。

例如：



常見儲存：

- Hadoop

- Amazon S3
- BigQuery
- Snowflake

3 Transform

資料已經存入系統後，再進行轉換。

例如：

- SQL
- Spark
- Python

ELT特點

特徵：

- 先存資料
- 再處理資料

優點：

- 適合大數據
- 可以保留原始資料
- 分析彈性高

缺點：

- 需要高效能資料倉儲
- 資料品質管理較複雜

三、ETL vs ELT 比較

項目	ETL	ELT
流程	Extract → Transform → Load	Extract → Load → Transform
資料處理時間	載入前	載入後
資料儲存	已整理資料	原始資料
適用環境	傳統資料倉儲	大數據 / Cloud
處理工具	ETL tools	Big Data tools
資料量	中小型資料	超大型資料

四、技術演進

資料架構的發展：

第一代

Database
↓
ETL
↓
Data Warehouse

第二代（Big Data）

Data Sources
↓
ELT
↓
Data Lake
↓
Analytics

五、常見工具

ETL工具

常見工具：

- Informatica
 - Talend
 - Pentaho
 - Microsoft SSIS
-

ELT / Big Data工具

常見工具：

- Apache Spark
 - Hadoop
 - Snowflake
 - Google BigQuery
-

六、醫療AI案例（課堂例子）

假設要建立 **Dental X-ray AI dataset**。

ETL流程

PACS
↓
Extract

影像整理
↓
Transform

AI Dataset
↓
Load

ELT流程

PACS
↓
Extract

Raw X-ray images
↓
Load (Data Lake)

AI preprocessing
↓
Transform

七、重要結論（課堂可強調）

傳統資料工程：

ETL

現代大數據 / Cloud：

ELT

因為現在：

- Storage 很便宜
- Cloud computing 很強

所以：

先存資料，再處理資料

八、給研究所學生的簡單記憶法

ETL

先整理 → 再存

ELT

先存 → 再整理

如果是 **研究所大數據分析課程**，下一個非常重要的觀念其實是：

Data Lake vs Data Warehouse vs Data Mart

這是 **資料工程 / AI 系統架構**的核心概念，很多學生其實會搞混。

如果需要，我可以幫您整理一份 **非常清楚的教學版（含圖示）**，通常一講學生就完全懂。