

爬蟲 404 錯誤解決

```
import requests
from bs4 import BeautifulSoup
import csv

url = "https://tw.news.yahoo.com/"
response = requests.get(url)
print(response.status_code)
-
Error : 404
可是URL直接貼在chrome是ok的
```

你這段程式其實 **邏輯沒有錯**，但 **requests** 有時候會被網站擋掉。
像 **Yahoo News** 這類網站常會檢查 **User-Agent**，如果判斷是程式爬蟲，就可能回傳 **404** 或 **403**。
也就是說：

- Chrome 連線 → 有瀏覽器資訊 → OK
- Python requests → 沒有瀏覽器資訊 → 被網站擋

解決方法：加入 User-Agent

```
import requests
from bs4 import BeautifulSoup
import csv

url = "https://tw.news.yahoo.com/"

headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) C"
}

response = requests.get(url, headers=headers)
print(response.status_code)
```

正常情況會變成：

```
200
```

為什麼要加 User-Agent

網站會看 request header，例如：

```
User-Agent: Mozilla/5.0 ...
```

Chrome 送出的 request 類似：

```
GET / HTTP/1.1
Host: tw.news.yahoo.com
User-Agent: Mozilla/5.0 ...
```

但 `requests` 預設是：

User-Agent: python-requests/2.31.0

很多網站會直接擋掉。

教學用完整爬 Yahoo 新聞標題範例（10分鐘版本）

```
import requests
from bs4 import BeautifulSoup

url = "https://tw.news.yahoo.com/"

headers = {
    "User-Agent": "Mozilla/5.0"
}

response = requests.get(url, headers=headers)

soup = BeautifulSoup(response.text, "html.parser")

titles = soup.find_all("h3")

for t in titles[:10]:
    print(t.text)
```

輸出：

```
新聞標題1
新聞標題2
新聞標題3
...
```

教學時可以順便講的3個重點

1 requests

→ 抓取網頁 HTML

2 BeautifulSoup

→ 解析 HTML

3 find / find_all

→ 抓出想要的資料

流程：

```
Website
↓
requests.get()
↓
HTML
↓
BeautifulSoup
↓
解析標籤
↓
取得資料
```

如果你願意，我可以幫你整理一個「10分鐘 Python 爬蟲完整教學投影片版」（非常適合你的大數據 Data Acquisition 課堂示範）。

內容會包含：

- 爬 Yahoo 新聞
- 抓標題
- 存 CSV
- 完整可跑程式

學生通常 **10 分鐘**就能成功爬資料。